Processamento de Linguagens
MiEI (3ºano)

Trabalho Prático nº 1 (FLex)

Ano lectivo 19/20

1 Objectivos e Organização

Este trabalho prático tem como principais **objectivos**:

- aumentar a experiência de uso do ambiente Linux e de algumas ferramentas de apoio à programação;
- aumentar a capacidade de escrever *Expressões Regulares (ER)* para descrição de *padrões de frases*;
- desenvolver, a partir de ERs, sistemática e automaticamente *Processadores de Linguagens Regulares*, que filtrem ou transformem textos com base no conceito de regras de produção *Condição-Ação*;
- utilizar o Flex para gerar *filtros de texto em C*.

Neste TP que se pretende que seja resolvido rapidamente (2 semana). Aprecia-se a imaginação/criatividade dos grupos ao incluir outros processamentos!

Deve entregar a sua solução **até Domingo dia 22 de Março**. O ficheiro com o relatório e a solução deve ter o nome '`pl19TP1GrNN`' — *em breve serão dadas indicações precisas sobre a forma de submissão.*
O programa desenvolvido será apresentado aos membros da equipa docente, totalmente pronto e a funcionar (acompanhado do respectivo relatório de desenvolvimento) e será defendido por todos os elementos do grupo, em data a marcar.
O **relatório** a elaborar, deve ser claro e, além do respectivo enunciado, da descrição do problema, das decisões que lideraram o desenho da solução e sua implementação (incluir a especificação FLex), deverá conter exemplos de utilização (textos fontes diversos e respectivo resultado produzido). Como é de tradição, o relatório será escrito em LaTeX.

2 Enunciados

Para sistematizar o trabalho que se pede em cada uma das propostas seguintes, considere que deve, em qualquer um dos casos, realizar a seguinte lista de tarefas:

1. Especificar os padrões de frases que quer encontrar no texto-fonte, através de ERs.
2. Identificar as acções semânticas a realizar como reacção ao reconhecimento de cada um desses padrões.
3. Identificar as Estruturas de Dados globais que possa eventualmente precisar para armazenar temporariamente a informação que vai extraindo do texto-fonte ou que vai construindo à medida que o processamento avança.
4. Desenvolver um Filtro de Texto para fazer o reconhecimento dos padrões identificados e proceder à transformação pretendida, com recurso ao Gerador FLex.

2.1 Template multi-file

Para várias projectos de software, é habitual soluções envolvendo vários ficheiros, várias pastas. Exemplo: um ficheiro, uma makefile, um manual, uma pasta de exemplos, etc.

Pretende-se criar um programa "mkfromtemplate", capaz de aceitar um nome de projecto, e um ficheiro descrição de um template-multi-file e que crie os ficheiros e pastas iniciais do projecto.

No exemplo abaixo apresenta-se um *template-multi-file* para um projecto geral de um filtro flex.

O template inclui:

- metadados (author, email) a substituir nos elementos seguintes
- tree (estrutura de directorias e ficheiros a criar)
- template da cada ficheiro

O metadado "name"vai ser processado via argumento de linha de comando.

```
=== meta

email: jj@di.uminho.pt
author: J.João
# "name" é dado por argumento de linha de comando (argv[1])

=== tree
{%name%}/
- {%name%}.fl
- doc/
-- {%name%}.md
- exemplo/
- Makefile

=== Makefile

{%name%}: {%name%}.fl
        flex {%name%}.fl
        cc -o {%name%} lex.yy.c

install: {%name%}
        cp {%name%} /usr/local/bin/

=== {%name%}.md
# NAME

{%name%} - o nosso fabuloso filtro ...FIXME

## Synopsis

   {%name%} file*

## Description
## See also
## Author

Comments and bug reports to {%author%}, {%email%}.

=== {%name%}.fl
%option noyywrap yylineno
%%

%%
int main(){
  yylex();
```

```
  return 0;
}
```

Modo de executar o programa: `mkfromtemplate name template`.
Como resultado da execução serão criados os ficheiros e directorias descritos em `tree`, com os conteúdos definidos nos templates de ficheiro, e as *variáveis* substituídas.

2.2 Filtro para gramáticas

Considere o seguinte extracto yacc contido num ficheiro de nome '`f.y`'.

```
  ....
  %union ....
  %token ID MKLISTA NULA
  %type ....
  %%
    lista : MKLISTA '(' ids ')' { ... ação semântica em C }
          | NULA
          ;
    ids : ID ',' ids   { ignorar as constantes char (ex: '!') das ações semânticas }
        | ID           { if ( ... == 'a') { ... } else { ...} }
        ;
  %%
  ... codigo C...
```

a) **Escreva um filtro flex** `extraiGIC` que extraia de '`f.y`' apenas a gramática pura, para ajudar na documentação:

```
lista : MKLISTA '(' ids ')'
      | NULA
      ;
ids : ID ',' ids
    | ID
    ;
```

b) Depois de escrever uma gramática, é preciso construir o analisador léxico associado, sendo fácil esquecer algum dos símbolos terminais.
Para ajudar os mais esquecidos, **escreva um filtro flex** `lexgen` que, dada um texto contendo uma gramática em notação yacc, gere o esqueleto de texto de um analisador léxico para essa gramática.
Este filtro deverá procurar a lista dos símbolos terminais da gramática (tokens) – tanto os expressamente definidos como tokens (`%token ...`), como os terminais que aparecem entre apostrofes nas produções da gramática (exemplo ',').
A execução de `lexgen f.y` (recorde que '`f.y`' é a gramática yacc apresentada acima) deverá gerar algo como se esquematiza abaixo (Note que a palavra `FIXME` no template será para o utilizador depois substituir pelas expressões regulares que definem os terminais (tokens) se podem escrever na sua linguagem concreta):

```
%%
FIXME {return ID;}
FIXME {return MKLISTA;}
FIXME {return NULA;}
[(),] {return yytext[0];}
%%
```

2.3 Drum Machine

Em notação abc podemos construir acompanhamentos ritmicos. (ver abcplus music notation para detalhes)
Considere o sequinte exemplo (Página html)`http://natura.di.uminho.pt/~jj/pl-20/TP1/abc_ui-perc.html`:

```
<!DOCTYPE html> <html> <head lang="en">
    <meta charset="UTF-8">
    <title>$ABC_UI</title>
    <link rel="stylesheet" href="http://dev.music.free.fr/css/music.min.css" />
    <script src="http://dev.music.free.fr/js/abc-ui-1.0.0.min.js"></script>
    <script src="http://dev.music.free.fr/js/music-ui-1.0.0.min.js"></script>
    <script src="http://dev.music.free.fr/soundfonts/percussion-mp3.js"></script>
    <style>pre { border: 2px solid lightgrey; border-radius: 3px; background: #EEE;}</style>
</head>
<body>
    <h4>Afoxé percussion patterns</h4>
    <div class="abc-source">
        X:1
        M:4/4
        L:1/4
        K:C clef=perc
        %%player_no_voice
        %%player_right
        %%map HT G  print=d % Agogo bell
        %%map LT _A print=G % Agogo bell
        %%map TD _G print=B % Tumba drum
        %%score [(H L) | T]
        %%stafflines .|.|
        %
        V:H name="Agogo"
        %%MIDI program 128
        %%voicemap HT
        %%pos stem down
        %
        V:L name="bell"
        %%MIDI program 128
        %%voicemap LT
        %%pos stem up
        %
        V:T name="Tumba\ndrum"
        %%MIDI program 128
        %%stafflines 1
        %%voicemap TD
        %%pos stem down
        %
        [V:H] x      x/ G/x/ G/ G  | x  x  G  G  :|
        [V:L] _A/_A/ z/ x/z/ x/ x  | _A _A x  x  :|
        [V:T] z2             _G _G | z2    _G _G :|
    </div>

<script>
    $ABC_UI.init();
</script>
</body>
</html>
```

Abrindo em HTML, podemos ver e ouvir esta padrão rítmico.
Considere agora os seguintes padrões rítmicos:

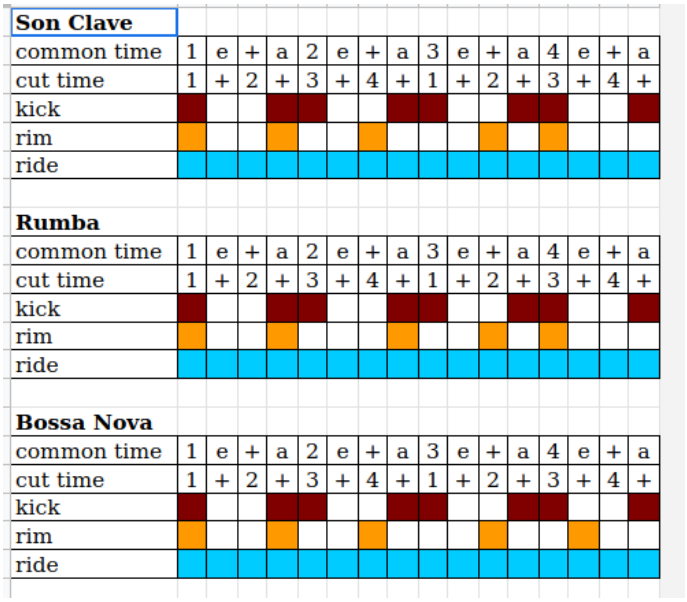

Pretende-se arranjar uma notação compacta e intuitiva de os descrever.

Defina uma notação para uma máquina de ritmos, faça um filtro flex que a transforme numa página `$ABC_UI` que os toque.

2.4 Transformador Publico2NetLang

Analise com todo o cuidado o ficheiro `http://natura.di.uminho.pt/~jj/pl-20/TP1/Publico_extraction_portuguese_comments_4.html` o qual contém os comentários (85 neste exemplo) a uma noticia publicada no jornal O Público, extraídos da página HTML da versão online do dito jornal.

Para se fazer um estudo sócio-linguístico de forma e conteúdo dos comentários que a notícia suscitou, os dados relevantes à análise pretendida devem ser extraídos do ficheiro HTML fornecido e devem ser transformados no formato JSON a seguir mostrado.

```
"commentThread": [
  {
    "id": "STRING",
    "user": "STRING",
    "date": "STRING",
    "timestamp": NUMBER,
    "commentText": "STRING",
    "likes": NUMBER,
    "hasReplies": TRUE/FALSE,
    "numberOfReplies": NUMBER

    "replies": [ ]
  },.......
]
```

Construa então um filtro de texto, recorrendo ao gerador FLex, que realize o processamento explicado, tendo em consideração que as respostas[1] que surjam a um dado comentário devem ser aninhadas, na forma de uma lista, dentro do campo `"replies"` do dito comentário, seguindo evidentemente o mesmo formato apresentado[2].

2.5 Transformador Sol2NetLang

Analise com todo o cuidado o ficheiro `http://natura.di.uminho.pt/~jj/pl-20/TP1/Sol4.html` o qual contém os comentários a uma noticia publicada no jornal Sol, extraídos da página HTML da versão online do dito jornal.

[1] Que também são comentários.

[2] Note que deve ser um processo recursivo.

Para se fazer um estudo sócio-linguístico de forma e conteúdo dos comentários que a notícia suscitou, os dados relevantes à análise pretendida devem ser extraídos do ficheiro HTML fornecido e devem ser transformados no formato JSON a seguir mostrado.

```
"commentThread": [
  {
    "id": "STRING",
    "user": "STRING",
    "date": "STRING",
    "timestamp": NUMBER,
    "commentText": "STRING",
    "likes": NUMBER,
    "hasReplies": TRUE/FALSE,
    "numberOfReplies": NUMBER

    "replies": [ ]
  },.......
]
```

Construa então um filtro de texto, recorrendo ao gerador FLex, que realize o processamento explicado, tendo em consideração que as respostas[3] que surjam a um dado comentário devem ser aninhadas, na forma de uma lista, dentro do campo `"replies"` do dito comentário, seguindo evidentemente o mesmo formato apresentado[4].

2.6 Transformador DailyExpress2NetLang

Analise com todo o cuidado o ficheiro `http://natura.di.uminho.pt/~jj/pl-20/TP1/DailyExpress1.html` o qual contém os comentários a uma noticia publicada no jornal inglês Daily Express, extraídos da página HTML da versão online do dito jornal.

Para se fazer um estudo sócio-linguístico de forma e conteúdo dos comentários que a notícia suscitou, os dados relevantes à análise pretendida devem ser extraídos do ficheiro HTML fornecido e devem ser transformados no formato JSON a seguir mostrado.

```
"commentThread": [
  {
    "id": "STRING",
    "user": "STRING",
    "date": "STRING",
    "timestamp": NUMBER,
    "commentText": "STRING",
    "likes": NUMBER,
    "hasReplies": TRUE/FALSE,
    "numberOfReplies": NUMBER

    "replies": [ ]
  },.......
]
```

Construa então um filtro de texto, recorrendo ao gerador FLex, que realize o processamento explicado, tendo em consideração que as respostas[5] que surjam a um dado comentário devem ser aninhadas, na forma de uma lista, dentro do campo `"replies"` do dito comentário, seguindo evidentemente o mesmo formato apresentado[6].

[3] Que também são comentários.
[4] Note que deve ser um processo recursivo.
[5] Que também são comentários.
[6] Note que deve ser um processo recursivo.